

SMARTWATCH E O SEU IMPACTO NA RECOLHA CONTÍNUA DE DADOS

Diogo Freitas (104841); daafs@iscte-iul.pt
Inês Silva (104912); imcsa1@iscte-iul.pt
João Botas (104782); jfmg3@iscte-iul.pt
Pedro Machado (98601); pbmoo@iscte-iul.pt

ISCTE-IUL

Av. Forças Armadas, 1649-026 Lisboa, Portugal

RESUMO

Com a evolução das novas tecnologias nos últimos anos, os relógios sofreram uma grande transformação, o que levou ao aparecimento do *smartwatch*. Assim, procuramos perceber a origem deste dispositivo e a forma como recolhe e processa os dados que obtém. Com o recurso a alguns exemplos, foram vistos os modelos e os sensores que permitem detetar as atividades do portador e os procedimentos que são realizados. Estes pontos serão explorados na perspetiva da área de Ciência de Dados e recorrendo à especulação do que será o futuro desta nova tecnologia.

Palavras-chave — *smartwatch*, dados, tecnologia, dispositivos, informação

1. INTRODUÇÃO

O desenvolvimento da tecnologia teve um grande impacto no estilo de vida do Homem, levando à transformação e evolução de diversos objetos usados pela nossa espécie. Um exemplo desta evolução são os relógios, que passaram do analógico para o digital e, na atualidade, para o *smartwatch*.

O *smartwatch* é visto, por muitos, como uma plataforma de entretenimento, no entanto, estes podem ter um grande impacto no dia a dia das pessoas, podendo oferecer opções de monitorização e apresentação de informação, de uma forma muito acessível. Sendo assim, este trabalho visa explorar e discutir as diversas funções que os *smartwatches* desempenham atualmente e as que poderão vir a desempenhar no futuro.

2. SMARTWATCH

2.1. O surgimento do *smartwatch*

Estes aparelhos são relativamente recentes, tendo sido um dos primeiros *smartwatches*, o Microsoft SPOT (*Smart Personal Object Technology*), lançado em 2004. O SPOT recebia informações como previsão do tempo, notícias e atualizações

de ações por meio de rádio FM. Também recebia e-mails e mensagens instantâneas, mas eram só de visualização. Com a ascensão do *smartphone*, surgiram relógios ainda mais inteligentes como o Sony Ericsson LiveView (2010), o Pebble (2013) e o Apple Watch (2015) que recebiam dados de um outro aparelho móvel. [1]

Algumas das razões exploradas pela **PwC**¹ para estes aparelhos passarem a ter uma adesão cada vez maior são por estes serem acessíveis, práticos, pela ajuda que dão na produtividade e no rastreamento de informação pessoal ou simplesmente pela sua beleza, estética e conotações sociais e económicas. [2]

2.2. As suas funcionalidades

Os *smartwatches* modernos incluem várias aplicações, semelhante aos *smartphones* e *tablets*, que oferecem funcionalidades adicionais, como a consulta de informação meteorológica, exibição de mapas e rotas e reprodução de música. A maioria dos *smartwatches* também podem ser utilizados para realizar chamadas telefónicas, enviar e receber mensagens de texto pela compatibilidade com o telemóvel.

Isso ocorre porque os dados são recebidos primeiro pelo telemóvel e depois enviados para o relógio. A maioria dos *smartwatches* não inclui Wi-Fi e não possui um cartão SIM, portanto, a maioria das aplicações depende mesmo de um *smartphone* compatível para fornecer dados através de uma conexão *Bluetooth*. Ainda assim, os *smartwatches* fornecem vários recursos que não exigem um *smartphone*, por exemplo, o rastreamento de atividades é possível ser feito usando o pedómetro e o monitor de frequência cardíaca, integrados no *smartwatch*.

Em termos de design, os *smartwatches* vêm em todas as formas e tamanhos, mas existem também diversas diferenças em relação ao *hardware* subjacente e nas funcionalidades e aplicações fornecidas. Os diferentes tipos de *smartwatches* mais comuns são os de uso geral, *fitness* e para desportos específicos. [3]

¹ **PwC** - *Price waterhouse coopers*- empresa influente em Portugal e no mundo no ramo da consultoria

3. RECOLHA E PARTILHA DE DADOS

3.1. CRISP-DM

O modelo de referência CRISP-DM fornece uma visão geral do ciclo de vida de um *data mining*. Ele contém as fases de um projeto, as suas respectivas tarefas e saídas.

O ciclo de vida de um projeto de *data mining* é dividido em seis fases que são enumeradas a seguir.

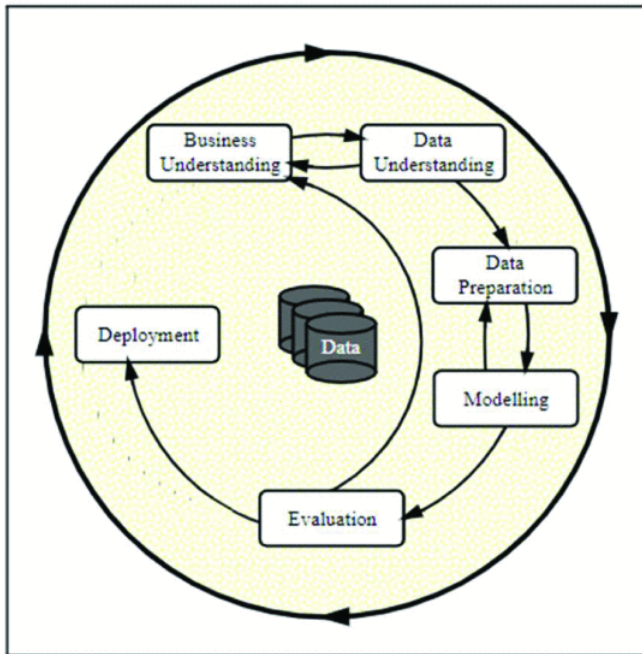


Fig.1 – Modelo CRISP-DM

1. Business Understanding: Esta fase inicial concentra-se na compreensão dos objetivos e requisitos do projeto a partir de uma perspectiva de negócios e, em seguida, esse conhecimento é convertido num problema de *data mining*, para depois se criar um plano projetado para atingir os objetivos.

2. Data Understanding: A fase de compreensão dos dados começa com uma recolha inicial dos mesmos e prossegue com atividades para se familiarizar, identificar problemas de qualidade, descobrir primeiro *insight* sobre os dados, ou para detetar subconjuntos interessantes para formar hipóteses sobre a informação escondida.

3. Data Preparation: A fase de preparação de dados abrange todas as atividades necessárias para construir o conjunto de dados final a partir dos dados brutos iniciais. As atividades necessárias incluem a criação de tabelas, registo, seleção e construção de atributos, limpeza de dados e transformação de dados para ferramentas de modelagem.

4. Modeling: Nesta fase várias técnicas de modelagem são selecionadas e aplicadas, sendo necessário calibrar os seus parâmetros a fim de obter valores ótimos. Existem várias técnicas para este tipo de *data mining*, mas algumas requerem formatos de dados específicos.

5. Evaluation: Nesta fase do projeto, é expectável que já se tenha chegado a um modelo que pareça ser de alta qualidade. Antes de prosseguir para a implementação final do modelo, é importante avaliá-lo mais detalhadamente, revendo todas as etapas já executadas, a fim de ter a certeza de que todos os objetivos foram atingidos.

6. Deployment: A criação de um modelo, geralmente, não está associada ao final do projeto. O conhecimento adquirido precisará ser organizado e apresentado de forma que se possa usá-lo. Dependendo dos requisitos, a fase de implementação pode ser tão simples quanto criar um relatório ou tão complexa como a implementação de um processo de *data mining*. [4]

3.2. Recolha dos dados por parte do *smartwatch*

Os *smartwatches* possuem sensores especiais já pré-instalados que monitorizam continuamente as ações e gestos dos usuários, alguns destes são:

- **Acelerômetro-** é usado para detetar o movimento humano, podendo até identificar a orientação do corpo humano. O principal fundamento do acelerômetro é converter o movimento cinético em medição digital.

- **Giroscópio-** é um dispositivo utilizado para medir a velocidade angular, sendo este utilizado para fins de navegação em barcos e navios, pois, este deteta a orientação e a rotação do usuário. Algumas empresas costumam colocar mais que 1 sensor, com objetivo de aumentar a precisão e filtrar os erros, facilitando assim o processo de coleta de dados e tornando-os mais próximos da realidade.

- **Sistema de Posicionamento Global (GPS)** - é o sensor mais comum no *smartwatch*, sendo este já utilizado por uma grande variedade de aplicações para conhecer a localização exata do utilizador, podendo assim exibi-la no próprio dispositivo ou enviar estes dados para a empresa fabricante do *smartwatch*. O GPS funciona com o suporte de um satélite.

- **Sensor de Pressão-** é um dispositivo que mede a pressão dos gases e dos líquidos. Este sensor é usado por milhares de aplicações diárias, relacionadas ao desporto e à área da saúde. Estes sensores também têm a capacidade de recolher outros tipos de dados, tais como, o fluxo do fluido/gás, velocidade, nível de água e altitude.

- **Sensor de frequência cardíaca-** Apesar de existirem vários sensores com a capacidade de detetar os batimentos cardíacos, este sensor também tem a capacidade de detetar os elétrodos, fazendo assim com que a pele se tome um condensador. Outra função que este sensor também consegue fazer, é a fotopletismografia, que é um fenómeno que usa a luz para sentir o fluxo sanguíneo, conectando-o assim a um batimento cardíaco.

- **Pedómetro** - é um sensor usado para contar os passos do utilizador, estando este a andar ou a correr. Existem duas versões do pedómetro - mecânico e elétrico.

3.3. Algoritmos de *machine learning*

O *Machine Learning* é a área mais importante da Inteligência Artificial, fornecendo, não só a possibilidade de criar previsões, como também a habilidade de encontrar padrões existentes em dados. Para que isto seja possível, é necessário que existam algoritmos para tal, cada um com a capacidade de analisar os dados de forma diferente, permitindo, assim, a existência de conclusões próprias.

Alguns dos Algoritmos de *Machine Learning* mais importantes são:

- **K-Nearest Neighbor (KNN)** é um algoritmo de aprendizagem supervisionado, sendo este um método não paramétrico, que usa a proximidade para fazer classificações ou previsões sobre o agrupamento de um ponto de dados individual.

- **Support Vector Machine (SVM)** é um modelo de aprendizagem de máquina supervisionado que usa algoritmos de classificação e regressão num *dataset*. Depois de fornecer a um modelo SVM conjuntos de dados de treinamento rotulados para cada categoria, este analisa os dados e reconhece os padrões, depois usado para os algoritmos citados.

- **Decision Tree (DT)** é um algoritmo de aprendizagem supervisionado utilizado para resolver problemas de classificação e regressão. A intenção geral de utilizar a Árvore de Decisão é fazer um modelo de preparação para prever a classe ou estimativa de fatores-alvo, adotando padrões de escolha construídos a partir de informações anteriores.

- **Logistic Regression (LR)** é um processo de modelagem da probabilidade de um resultado discreto dada uma variável de entrada.

- **Naïve Bayes (NB)** é um modelo de *Machine Learning* baseado no Teorema de *Bayes* para a tarefa de classificação. [7]

4. IMPLEMENTAÇÃO DE MACHINE LEARNING NA ÁREA DA SAÚDE

Uma das coisas mais habituais de se associar a um *smartwatch* é a realização de atividades desportivas, pois estes têm a capacidade de recolher dados tais como a frequência cardíaca, os passos dados e o nível de oxigénio no sangue, que são relevantes e associados à saúde.

Tendo isto em conta, uma equipa de investigadores financiados pelo **NIH**² teve a ideia de usar esses sensores como forma de prever resultados de testes clínicos, o que poderia servir como um sinal de alerta precoce para problemas de saúde subjacentes. Para entender melhor como os *smartwatches* poderiam ser incorporados à rotina de saúde, os autores do estudo avaliaram primeiro os dados capturados pelo *smartwatch* e, de seguida, compararam com as medições

feitas em um ambiente clínico. Para fazer isso, eles acompanharam 54 participantes por, aproximadamente, 3 anos. Durante esse período, cada participante teve cerca de 40 consultas clínicas e usou o dispositivo por 340 dias. O *smartwatch* mediu quatro sinais vitais: frequência cardíaca, temperatura da pele, contagem de passos e atividade eletrodérmica.

Após a recolha dos dados foram realizadas comparações entre os valores obtidos concluindo-se que as medições de temperatura eram mais consistentes quando avaliadas em um ambiente clínico, já que a temperatura oral geralmente tinha menos variabilidade do que a temperatura da pele medida pelo *wearable*. No entanto, o *smartwatch* forneceu leituras de frequência cardíaca mais precisas, pois as medições feitas na clínica tinham significativamente mais variabilidade; sendo fatores como a hora do dia, a atividade que estava a ser feita antes da consulta ou até se o paciente estaria nervoso durante a consulta. “Por outro lado, como um *smartwatch* é usado continuamente, a frequência cardíaca do usuário pode ser medida ao longo do dia, resultando em uma medição muito mais consistente com variabilidade significativamente menor”, explicou o autor do estudo Michael Snyder, Ph.D., presidente do Departamento de Genética da Faculdade de Medicina da Universidade de Stanford.

Com os resultados obtidos, os investigadores quiseram determinar se poderiam prever os resultados dos testes laboratoriais clínicos usando as informações recolhidas dos *smartwatches*. Então, compararam os resultados previstos gerados a partir dos seus modelos com os resultados observados nos testes de laboratório realizados na clínica.

Desta forma, os investigadores descobriram que as medições relacionadas à atividade eletrodérmica foram um fator importante na previsão dos resultados dos testes de glóbulos vermelhos, hemoglobina e hematócrito.

Outras medições do *smartwatch*, não referidas anteriormente, foram fundamentais na previsão de resultados específicos de exames de sangue. Por exemplo, as medidas mais importantes para prever a contagem absoluta de monócitos foram baseadas na contagem de passos e na temperatura da pele. Por outro lado, a previsão da contagem de plaquetas baseou-se em medidas relacionadas à frequência cardíaca, enquanto a previsão da glicemia de jejum usou uma combinação de medidas de temperatura da pele, frequência cardíaca e contagem de passos. “Nossos resultados sugerem que diferentes características fisiológicas estão associadas à previsão de medidas clínicas distintas”, observou a autora Jessilyn Dunn, Ph.D., professora assistente de engenharia biomédica na Duke University.

Os investigadores assim concluíram que apesar dos dados do *smartwatch* não substituírem os testes clínicos, estes podem servir como um sinal de alerta precoce, podendo levar

² **NIH** - National Institutes of Health é a principal agência governamental dos EUA responsável pela biomedicina e pela pesquisa da saúde pública.

o utilizador a consultar um médico. “O poder dos dispositivos vestíveis é a sua capacidade de captar alterações das leituras da linha de base”, disse Snyder. Mesmo que algumas medidas específicas não sejam altamente precisas, a capacidade do relógio de detetar mudanças nos sinais vitais da pessoa pode ser imensamente útil. “O paradigma médico atual concentra-se no tratamento de pacientes depois deles já estarem doentes, não na monitorização de pessoas saudáveis para a detecção precoce da doença”, disse Snyder. “Acreditamos que os dados dos smartwatches podem ajudar a intercepar doenças emergentes, o que poderia prevenir doenças mais graves.” [8]

5. RECONHECIMENTO DE ATIVIDADES: ABORDAGEM DE MACHINE LEARNING

No artigo “*Smartwatch-based activity recognition: A machine learning approach*” [9] foram realizados testes, onde compararam a capacidade do *smartwatch* e do *smartphone* de reconhecerem as atividades das pessoas, sabendo se eles estão a, por exemplo, caminhar, correr ou a comer.

Até recentemente só era possível reconhecer as atividades e a condição física de uma pessoa através de dispositivos especializados e concebidos para tal, onde estes eram colocados pelo corpo dessa mesma pessoa. Com o desenvolvimento tecnológico, os *smartphones* passaram a ter a capacidade de fazer o mesmo, graças aos sensores já neles equipados, tais como os acelerómetros e giroscópios. Graças ao uso intensivo destes aparelhos, pela maioria das pessoas possuírem um, houve uma grande evolução nas aplicações de reconhecimento de atividades e condições físicas do utilizador. Isto levou ao surgimento de novos problemas, tais como, a limitação e a dificuldade nos resultados e no reconhecimento das atividades dos utilizadores, devido à má localização do dispositivo, graças ao costume de colocar os *smartphones* no bolso das calças, o que dificulta o rastreamento de atividades manuais. Já os *smartwatches* ultrapassam essas limitações uma vez que estes são usados no mesmo local constantemente, estando num local ideal para conseguir rastrear as atividades dos utilizadores. Para além disso, como praticamente todos os *smartwatches* estão conectados a um *smartphone*, as informações dos sensores destes dispositivos trabalham em conjunto, com o objetivo de obter resultados mais confiáveis.

Este estudo tem como objetivo reconhecer várias atividades, incluindo, atividades manuais, tais como, a digitação e a escrita, atividades relacionadas à alimentação, como, por exemplo, comer sopa, comer uma sandes e beber. Os modelos de classificação são induzidos a partir de dados de treino rotulados usando algoritmos de *machine learning*.

Caso estes dispositivos estejam cientes do que o utilizador está a fazer, estes podem operar de forma mais inteligente, podendo reencontrar uma chamada para o correio de voz durante uma refeição. No entanto, o principal objetivo desta pesquisa foi melhorar a saúde e o bem-estar das pessoas. É referido que a inatividade física e a alimentação não saudável são dois dos fatores de risco que

mais prejudicam a saúde e contribuem para o desenvolvimento de doenças. Uma forma de ajudar a combater esta inatividade e a ingestão em excesso de comida é a monitorização das atividades do utilizador, fornecendo assim informações precisas e em tempo real sobre comportamento sedentário, exercícios e comportamento alimentar. O *smartwatch* tem o benefício de estar sempre acessível de forma rápida e discreta, podendo transmitir informações muito facilmente, tais como, uma dieta mais saudável para o utilizador e exercícios específicos para o mesmo.

A tarefa de reconhecimento de atividades necessita de sensores, já inseridos em *smartwatches* e em *smartphones*, que tenham a capacidade de reconhecer a atividade que está a ser realizada. Nesta experiência, a atividade será executada num intervalo de 10 segundos e, caso o aparelho acerte a atividade que está a ser realizada no intervalo de tempo, significa que a atividade foi reconhecida corretamente.

Atividades sem uso das mãos	Atividades com uso das mãos	Atividades alimentares
Andar	Driblar uma bola	Comer massa
Correr	Jogar Ténis	Comer sopa
Subir as escadas	Digitar	Comer uma sandes
Sentar	Escrever	Comer Batatas Fritas
Estar em pé	Bater Palmas	Beber de um copo
Chutar uma bola	Lavar os dentes	
	Dobrar a roupa	

Tabela 1 – Reconhecimento de atividades

A metodologia associada à produção e avaliação dos modelos de reconhecimento de atividades será apresentada daqui para a frente, onde serão demonstrados os procedimentos de coleta de dados, o método para transformar os dados do sensor de série temporal de baixo nível em exemplos e o processo de indução do modelo.

5.1. Data collection

Os dados deste estudo foram coletados de 17 sujeitos, onde cada um realizou as 18 atividades listadas na Tabela 1. Cada sujeito realizou a atividade durante 2 minutos, enquanto possuía um *smartwatch* no seu braço dominante e um *smartphone*, emparelhado com o *smartwatch*, no seu bolso frontal direito. Os dados foram coletados por um *smartwatch* LG G Watch e um *smartphone* Samsung Galaxy S4, ambos operando com o sistema Android Wear.

A aplicação utilizada para coletar os dados, instalado tanto no *smartwatch* e no *smartphone*, utilizava o acelerómetro e o giroscópio no telefone e no relógio a uma

taxa de 20Hz, com cada sensor a fornecer dados nas três dimensões.

Após a finalização de uma atividade o *smartphone* envia automaticamente os dados, em uma mensagem de e-mail, para um servidor, onde este é armazenado a fim de ser comparado e estudado posteriormente.

De forma que todos os dados recolhidos estivessem corretos, foram realizados ajustes na hora de recolha de dados, cortando as partes que poderiam influenciar as conclusões, pois, havia participantes que começavam a atividade mais tarde, ou outros que acabavam mais cedo.

5.2. Data transformation

Os algoritmos de classificação convencionais não têm a capacidade de operar em dados de séries temporais, portanto, esses dados, precisaram de ser transformados em blocos de dados de 10 segundos, cada um deles possuindo recursos de nível superior que continham a capacidade de descrever o comportamento durante esse período de tempo.

Estes recursos de nível superior baseiam-se em 43 tipos de dados, sendo alguns deles, o cálculo de médias, desvios padrões e outras medidas dos valores dos eixos x, y e z para o sensor.

5.3. Model induction

Os modelos de *machine learning* usados neste estudo foram retirados do algoritmo **WEKA**³ [10]. Alguns exemplos deste são: *Random Forest* (RF), algoritmo de árvore de decisão J48, algoritmo de aprendizado baseado em instância IB3, algoritmo NB e o *perceptron* multicamada (algoritmo MLP). Existem dois tipos de modelos induzidos. Os modelos pessoais, utilizam apenas dados do utilizador pretendido, enquanto nos modelos impessoais são criados dados de treino de todos, exceto do utilizador pretendido.

Uma pesquisa já realizada anteriormente, demonstrou que os modelos pessoais superam amplamente os modelos impessoais para reconhecimento de atividades [11], mas ao custo de exigir que cada usuário forneça dados de treinamento rotulados.

5.4. Resultados finais

De seguida, poderemos ver os resultados finais dos testes realizados. Os resultados para os modelos de reconhecimento de atividade pessoal e impessoal são apresentados na Tabela 2 e na Tabela 3, respetivamente.

Os resultados são medidos usando a precisão da classificação, que neste caso corresponde ao percentual das classificações que identificam corretamente a atividade que o utilizador está a efetuar. Cada modelo utiliza um único sensor-modelo usando o acelerómetro do relógio, o

acelerómetro do telefone e o giroscópio do relógio. Todos os resultados da Tabela 2 e 3 são baseados em 17 sujeitos de teste que realizaram as 18 atividades listadas na Tabela 1.

Algorithm	Phone accel (%)	Watch accel (%)	Watch gyroscope (%)
RF	75.5	93.3	79.0
J48	65.5	86.1	73.0
IB3	67.7	93.3	60.1
NB	77.1	92.7	80.2
MLP	77.0	94.2	70.0
Ave	72.6	91.9	72.4

Tabela 2 – Modelos Pessoais

Algorithm	Phone accel (%)	Watch accel (%)	Watch gyroscope (%)
RF	35.1	70.3	57.5
J48	24.1	59.3	49.6
IB3	22.5	62.0	49.3
NB	26.2	63.8	53.5
MLP	18.9	64.6	57.7
Ave	25.3	64.0	53.5

Tabela 3 – Modelos Impessoais

Como já era esperado, os modelos pessoais superam os modelos impessoais, embora sejam construídos usando muito menos dados de treino. Os resultados também demonstram que o acelerómetro do relógio oferece resultados muito melhores do que o acelerómetro do telefone, com uma precisão média de 91,9% versus 72,6% para modelos pessoais e 64,0% versus 25,3% para modelos impessoais.

Essas diferenças são em grande parte devido às atividades manuais incluídas neste estudo. O giroscópio do relógio tem um desempenho muito pior do que o acelerómetro do relógio, com uma precisão média de 72,4% versus 91,9% para os modelos pessoais e 53,5% versus 64,0% para os modelos impessoais.

Os resultados das precisões presentes nas tabelas serão muito importantes de se examinar, pois, a partir da examinação destes, poderemos determinar quais são as atividades mais fáceis de reconhecer e quais são as mais difíceis de reconhecer. Devido a limitações de espaço, a análise do estudo foi focada em modelos induzidos usando o algoritmo RF, uma vez que este algoritmo tem um bom desempenho nas 6 configurações (3 sensores e 2 tipos de modelos). As precisões dos modelos de RF, nas 18 atividades para modelos pessoais e impessoais, são mostradas na Tabela 4.

³ **WEKA** - Waikato Environment for Knowledge Analysis é um pacote de software escrito em Java.

Activity	Impersonal (%)			Personal (%)		
	Watch accel	Phone accel	Watch gyro	Watch accel	Phone accel	Watch gyro
Walking	79.8	60.7	87.0	94.2	88.5	93.5
Jogging	97.7	93.8	48.6	99.2	68.8	98.1
Stairs	58.5	66.7	43.1	88.9	66.7	80.0
Sitting	84.9	26.9	70.5	97.5	87.0	82.2
Standing	96.3	65.9	57.9	98.1	73.1	68.6
Kicking	71.3	72.5	41.4	88.7	91.7	67.9
Dribbling	89.3	26.1	86.0	98.7	84.8	96.9
Catch	66.0	26.1	68.9	93.3	78.3	94.6
Typing	80.4	76.9	60.8	99.4	72.0	88.6
Handwriting	85.2	12.9	63.1	100.0	75.9	80.5
Clapping	76.3	40.9	67.9	96.9	77.3	95.6
Brush Teeth	84.5	19.2	66.2	97.3	96.2	89.6
Fold Clothes	80.8	8.3	37.8	95.0	79.2	73.1
Eat Pasta	47.1	0.0	57.9	88.6	40.0	72.9
Eat Soup	52.7	0.0	47.7	90.7	82.4	69.8
Eat Sandwich	29.0	7.1	31.1	68.9	63.0	44.2
Eat Chips	65.0	16.0	50.6	83.4	76.0	52.5
Drink	62.7	31.8	61.1	93.3	77.3	78.5
Overall	70.3	35.1	57.5	93.3	75.5	79.0

Tabela 4 – As previsões das atividades

Visualizando os resultados, é possível notar que o último grupo de atividades, as atividades alimentares, parecem ter uma menor precisão quando comparado aos resultados dos outros dois grupos. Isso sugere que, talvez, por as atividades alimentares serem semelhantes, estas dificultem a previsão de cada uma, fazendo com que estas sejam confundidas facilmente. Também vemos que o sensor do telemóvel tem um desempenho muito pior do que os dois sensores do relógio para a atividade alimentar, tanto nos modelos impessoais como nos pessoais. Isso provavelmente se deve ao fato de que muitas das atividades manuais no segundo grupo também envolvem movimentos corporais significativos. Ao observarmos os resultados dos modelos pessoais construídos a partir do sensor do acelerómetro do relógio, vemos que a atividade mais difícil de reconhecer é o “*Eat a sandwich*”, que tem uma precisão de 68,9%.

5.5. Em síntese

Este artigo demonstra que o reconhecimento de atividades baseado em *smartwatch* é capaz de reconhecer uma ampla variedade de atividades, incluindo algumas atividades que um smartphone não consegue reconhecer efetivamente. No geral, os resultados deste artigo sugerem que os *smartwatches* comerciais podem reconhecer uma ampla variedade de atividades com precisão relativamente boa. Os resultados mostram ainda que os modelos pessoais têm melhor desempenho – especialmente para as atividades alimentares. Este artigo também compara o desempenho do acelerômetro e do giroscópio para reconhecimento de atividade, e o acelerômetro do relógio mostra um desempenho significativamente superior ao do giroscópio do relógio.

6. CONCLUSÃO

É notório que o grande e rápido desenvolvimento tecnológico, que tem vindo a acontecer nos anos, tem vindo a mudar a forma como pensamos e vivemos.

Este trabalho teve o *Smartwatch* como o tema principal e abordou como é feita a recolha dos dados, sendo esta recolha mais eficiente que a realizada por parte dos telemóveis. Esta recolha contínua dos dados permite que se obtenha variadas informações sobre o utilizador, podendo assim usá-las para se fazerem previsões valiosas. Esta recolha continua contribui para vários setores de atividade, como para conseguir identificar as ações, a localização e a saúde das pessoas, podendo desta forma ajudar rapidamente em caso de emergência.

REFERÊNCIAS

- [1] Bloomberg - Are you a robot? (2019). Bloomberg.com. <https://www.bloomberg.com/news/articles/2018-01-08/a-concise-history-of-the-smartwatch>
- [2] Consumer Intelligence Series. (2016). <https://www.pwc.com/ee/et/publications/pub/pwc-cis-wearables.pdf>
- [3] Smartwatch | Britannica. (2019). In Encyclopædia Britannica <https://www.britannica.com/technology/smartwatch>
- [4] Wirth, R., & Hipp, J. (2000). CRISP-DM: Towards a Standard Process Model for Data Mining. <http://www.cs.unibo.it/~danilo.montesi/CBD/Beatriz/10.1.1.1.98.5133.pdf>
- [5] Saleh, S. J., Ali, S. Q., & Zeki, A. M. (2020). Random Forest vs. SVM vs. KNN in classifying Smartphone and Smartwatch sensor data using CRISP-DM. 2020 International Conference on Data Analytics for Business and Industry: Way towards a Sustainable Economy (ICDABI). <https://doi.org/10.1109/icdabi51230.2020.9325607>
- [6] Bonaccorso, G. (2017). Machine Learning Algorithms. In Google Books. Packt Publishing Ltd. <https://books.google.pt/books?hl=pt-PT&lr=&id=-ZDDwAAQBAJ&oi=fnd&pg=PP1&dq=>
- [7] Ray, S. (2019, February 1). A Quick Review of Machine Learning Algorithms. IEEE Xplore. <https://doi.org/10.1109/COMITCon.2019.8862451>
- [8] Smartwatch data used to predict clinical test results. (n.d.). Www.nibib.nih.gov. Retrieved May 25, 2022, from <https://www.nibib.nih.gov/news-events/newsroom/smartwatch-data-used-predict-clinical-test-results-4>
- [9] Weiss, G. M., Timko, J. L., Gallagher, C. M., Yoneda, K., & Schreiber, A. J. (2016, February 1). Smartwatch-based activity recognition: A machine learning approach. IEEE Xplore. <https://doi.org/10.1109/BHI.2016.7455925>
- [10] I. H. Witten and E. Frank, Data Mining: Practical Machine Learning Tools and Techniques, Morgan Kaufmann, 2005.
- [11] J. W. Lockhart and G. M. Weiss, "The benefits of personalized models for smartphone-based activity recognition", *Proc of the 2014 SIAM International Conference on Data Mining*, pp. 614-622.